

10

Regression Analysis

回归分析

线性回归结果不能拿来就用



真理太复杂了，除了近似，我们别无他法。

Truth is much too complicated to allow anything but approximations.

—— 约翰·冯·诺伊曼 (John von Neumann) | 美国籍数学家 | 1903 ~ 1957



- ◀ seaborn.pairplot() 绘制成对分析图
- ◀ statsmodels.api.add_constant() 线性回归增加一列常数 1
- ◀ statsmodels.api.OLS() 最小二乘法函数
- ◀ statsmodels.stats.anova.anova_lm 获得 ANOVA 表格
- ◀ scipy.stats.t.sf() 求解 t 分布的互补累积分布函数 $CCDF = 1 - CDF$
- ◀ scipy.stats.t.ppf() 求解 t 分布的逆累积分布函数
- ◀ seaborn.regplot() 绘制回归图像
- ◀ statsmodels.api.add_constant() 线性回归增加一列常数 1
- ◀ statsmodels.api.OLS() 最小二乘法函数
- ◀ scipy.stats.skew() 计算偏度
- ◀ scipy.stats.kurtosis() 计算峰度
- ◀ scipy.stats.normaltest() Omnibus 正态检验
- ◀ seaborn.distplot() 绘制直方图，叠合 KDE 曲线
- ◀ statsmodels.graphics.tsaplots.plot_acf() 绘制自相关结果



10.1 线性回归：一个表格、一条直线

一个表格

大家是否还记得我们在《统计力量》第 24 章给出过图 1 这个表格。这个表格总结的是一个线性回归分析的结果。本章的主要目的就是和大家理解这个表格各项数值的含义。下面首先介绍这个表格具体来自哪个线性回归。

```

OLS Regression Results
=====
Dep. Variable:          AAPL      R-squared:                0.687
Model:                  OLS      Adj. R-squared:           0.686
Method:                 Least Squares   F-statistic:             549.7
Date:                  XXXXXXXXXX   Prob (F-statistic):      4.55e-65
Time:                  XXXXXXXXXX   Log-Likelihood:         678.03
No. Observations:      252        AIC:                    -1352.
Df Residuals:          250        BIC:                    -1345.
Df Model:               1
Covariance Type:       nonrobust
=====
                    coef    std err          t      P>|t|      [0.025    0.975]
-----
const             0.0018      0.001      1.759      0.080     -0.000      0.004
SP500             1.1225      0.048     23.446      0.000      1.028      1.217
=====
Omnibus:           52.424    Durbin-Watson:           1.864
Prob(Omnibus):     0.000    Jarque-Bera (JB):        210.803
Skew:              0.777    Prob(JB):                1.68e-46
Kurtosis:          7.203    Cond. No.                 46.1
=====

```

图 1. 一元线性回归结果

一条直线

图 2 所示为这个一元 OLS 线性回归的自变量、因变量散点数据以及分布特征。自变量为一段时间内标普 500 股票指数日收益率，因变量为某只特定股票的同期日收益率。观察散点图，我们可以发现明显的“线性”关系。

从金融角度，股指可以“解释”同一个市场上股票的涨跌。再次强调，线性回归不代表“因果关系”。图 1 是利用 statsmodels.api.OLS() 函数构造的线性模型结果。

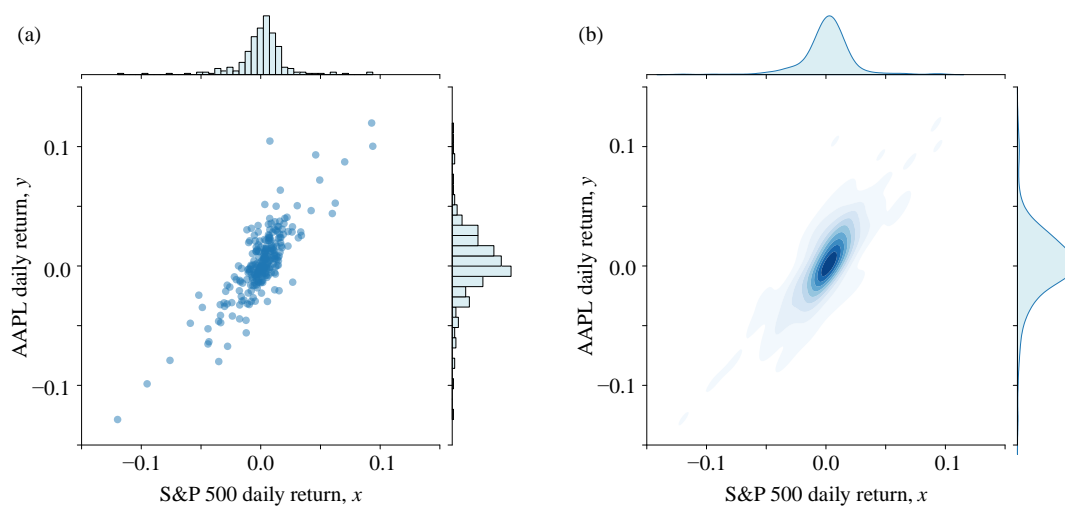



图 2. 日收益率数据关系

图 3 所示为用 `seaborn.jointplot()` 绘制回归图，并且绘制边际分布。

图 3. 用 `seaborn.jointplot()` 绘制回归直线

统计特征

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

图 4 (a) 所示为数据的协方差矩阵。《统计至简》第 12、24 章介绍过如何从条件概率角度理解线性回归。假设 X 和 Y 的均值为 0，请大家根据这个协方差矩阵写出线性回归解析式。

图 4 (b) 所示为相关性系数矩阵热图。《矩阵力量》第 23 章介绍过相关性系数可以看成是“标准差向量”之间夹角，具体如图 4 (c) 所示。

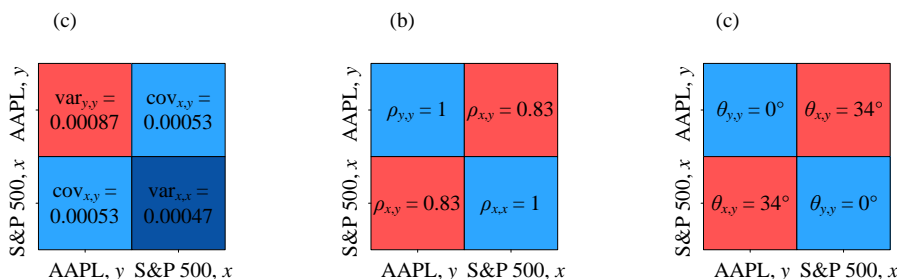


图 4. $[y, x]$ 数据的协方差矩阵、相关性和夹角热图

图 5 所示为两个标准差向量的箭头图。夹角越小，说明因变量向量 y 和自变量向量 x 越相近。也就是说，夹角越小，自变量向量 x 能更充分解释因变量向量 y 。本章后文还会利用这个几何视角解释回归分析结果。

本章内容相对比较枯燥，建议大家主要理解 ANOVA。本章其余内容，大家有实际需要时再回头查阅。




图 5. 标准差向量空间角度解释夹角



Bk6_Ch10_01.py 绘制本节图像。

10.2 方差分析 ANOVA

本节开始先介绍如何理解图 6 所示的 ANOVA 表格结果。ANOVA 的含义是方差分析 (Analysis of Variance)。ANOVA 是图 1 的重要组成部分之一。

	df	sum_sq	mean_sq	F	PR(>F)
x	1.0	0.149314	0.149314	549.729877	4.547141e-65
Residual	250.0	0.067903	0.000272	NaN	NaN

图 6. 一元线性回归 ANOVA 表格，来自本书第 6 章

表 1 所示为标准 ANOVA 表格对应的统计量。标准 ANOVA 表格比图 6 多一行。表 1 有五列：

第 1 列为计算方差的三个来源；

第 2 列 df 代表自由度 (degrees of freedom)；

第 3 列 SS 代表 Sum of Squares；

第 4 列 MS 代表 Mean Sum of Squares；

第 5 列 F 代表 F -test 统计量。

表中 n 代表参与回归的非 NaN 样本数量。 k 代表回归模型参数数量，包括截距项。 D 代表因变量的数量，因此 $k = D + 1$ 。下面将逐个解密表 1 中的每一个值的含义，以及它们和线性回归的关系。

表 1. ANOVA 表格

Source	df	SS	MS	F	Significance
Regressor	$DFR = D = k - 1$	SSR	$MSR = SSR/DFR$	$F = MSR/MSE$	p -value of F -test
Residuals	$DRE = n - D - 1 = n - k$	SSE	$MSE = SSE/DRE$		
Total	$DFT = n - 1$	SST			

三个平方和

为了理解 ANOVA 表格，我们首先要了解三个平方和：

- ◀ **总离差平方和** (Sum of Squares for Total, SST)，也称 TSS (total sum of squares)；
- ◀ **残差平方和** (Sum of Squares for Error, SSE)，也称 RSS (residual sum of squares)；

◀ **回归平方和** (Sum of Squares for Regression, SSR), 也称 ESS (explained sum of squares)。

图 7 给出计算三个平方和所需的数值。表 2 总结了三个平方和的定义。




图 7. 通过一元线性回归模型分解因变量的变化

表 2. 三个平方和的定义

平方和	定义	图像
总离差平方和 (Sum of Squares for Total, SST)	$SST = \sum_{i=1}^n (y^{(i)} - \bar{y})^2$	
回归平方和 (Sum of Squares for Regression, SSR)	$SSR = \sum_{i=1}^n (\hat{y}^{(i)} - \bar{y})^2$	
残差平方和 (Sum of Squares for Error, SSE)	$SSE = \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2$	

等式关系

对于线性回归来说，方差分析 (analysis of variance) 实际上就是分解总离差平方和 SST。把 SST 分解成残差平方和 SSE、回归平方和 SSR：

$$SST = SSR + SSE \quad (1)$$

即：

$$\underbrace{\sum_{i=1}^n (y^{(i)} - \bar{y})^2}_{SST} = \underbrace{\sum_{i=1}^n (\hat{y}^{(i)} - \bar{y})^2}_{SSR} + \underbrace{\sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2}_{SSE} \quad (2)$$

上式的证明并不难，本节不做展开讲解，本章后续会用向量几何视角解释以上等式关系。

本章后续将介绍由这三个平方和引出的一些列有关回归的统计量，特别是 R-squared 和 Adj. R-squared。

10.3 总离差平方和 SST

总离差平方和 (Sum of Squares for Total, SST) 代表因变量 y 所有样本点与期望值 \bar{y} 的差异：

$$SST = \sum_{i=1}^n (y^{(i)} - \bar{y})^2 \quad (3)$$

其中，期望值 \bar{y} 为：

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y^{(i)} \quad (4)$$

如图 8 所示，SST 可以看做一系列正方形面积之和。这些正方形的边长为 $|y^{(i)} - \bar{y}|$ 。图 8 中这些正方形的一条边都在期望值 \bar{y} 这个高度上。




图 8. 总离差平方和 SST

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

总离差自由度 DFT

总离差自由度 (degree of freedom total, DFT) 的定义为：

$$DFT = n - 1 \quad (5)$$

n 是样本数据的数量 (NaN 除外)。

三个自由度关系

总离差自由度 DFT、回归自由度 DFR、残差自由度 DFE 三者关系为：

$$DFT = n - 1 = DFR + DFE = \underbrace{(k - 1)}_{DFR} + \underbrace{(n - k)}_{DFE} = \underbrace{(D)}_{DFR} + \underbrace{(n - D - 1)}_{DFE} \quad (6)$$

k 是回归模型的参数，其中包括截距项。因此，

$$k = D + 1 \quad (7)$$

D 为参与回归模型的特征数，也就是因变量的数量。

举个例子，对于一元线性回归， $D = 1$ ， $k = 2$ 。如果参与建模的样本数据为 $n = 252$ ，几个自由度分别为：

$$\begin{cases} DFT = 252 - 1 = 251 \\ k = D + 1 = 2 \\ DFR = k - 1 = D = 1 \\ DFE = n - k = n - D - 1 = 252 - 2 = 250 \end{cases} \quad (8)$$

平均总离差 MST

平均总离差 (mean square total, MST) 的定义为：

$$MST = \text{var}(Y) = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1} = \frac{SST}{DFT} \quad (9)$$

实际上，总离差 MST 便是因变量 Y 样本数据方差。看到这里，大家应该理解为什么本章的内容叫“方差分析”了。

10.4 回归平方和 SSR

回归平方和 (Sum of Squares for Regression, SSR) 代表回归方程计算得到的预测值 $\hat{y}^{(i)}$ 和期望值 \bar{y} 之间的差异：

$$SSR = \sum_{i=1}^n (\hat{y}^{(i)} - \bar{y})^2 \quad (10)$$

图 9 所示为回归平方和 SSR 的几何意义。图 9 中的每个正方形边长为 $|\hat{y}^{(i)} - \bar{y}|$ 。




图 9. 回归平方和

回归自由度 DFR

回归自由度 (degrees of freedom for regression model, DFR) 为：

$$DFR = k - 1 = D \quad (11)$$

平均回归平方 MSR

平均回归平方 (mean square regression, MSR) 为：

$$MSR = \frac{SSR}{DFR} = \frac{SSR}{k-1} = \frac{SSR}{D} \quad (12)$$

10.5 残差平方和 SSE

残差平方和 (Sum of Squares for Error, SSE) 定义如下：

$$SSE = \sum_{i=1}^n (\varepsilon^{(i)})^2 = \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2 \quad (13)$$

相信大家对残差平方和 SSE 已经很熟悉。比如，在最小二乘法中，我们通过最小化残差平方和 SSE 优化回归参数。

图 10 所示为残差平方和 SSE 的示意图。图中每个正方形的边长为 $|y^{(i)} - \hat{y}^{(i)}|$ 。




图 10. 残差平方和 SSE

残差自由度 DFE

残差自由度 (degrees of freedom for error, DFE) 为：

$$DFE = n - k = n - D - 1 \quad (14)$$

残差平均值 MSE

残差平均值 (mean squared error, MSE) 为：

$$MSE = \frac{SSE}{DFE} = \frac{SSE}{n - k} = \frac{SSE}{n - D - 1} \quad (15)$$

均方根残差 RMSE

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

均方根残差 (Root mean square error, RMSE) 为 MSE 的平方根:

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{\text{SSE}}{\text{DFE}}} = \sqrt{\frac{\text{SSE}}{n-p}} = \sqrt{\frac{\text{SSE}}{n-D-1}} \quad (16)$$

10.6 几何视角：勾股定理

大家别忘了《矩阵力量》反复提到的几何视角!

一个直角三角形

看到 (2) 中三个求和，我们下面用向量方法完成三个求和运算：

$$\begin{aligned} \text{SST} &= \sum_{i=1}^n (y^{(i)} - \bar{y})^2 = \|\mathbf{y} - \bar{y}\mathbf{I}\|_2^2 \\ \text{SSR} &= \sum_{i=1}^n (\hat{y}^{(i)} - \bar{y})^2 = \|\hat{\mathbf{y}} - \bar{y}\mathbf{I}\|_2^2 \\ \text{SSE} &= \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2 = \|\mathbf{y} - \hat{\mathbf{y}}\|_2^2 \end{aligned} \quad (17)$$

根据 (2)，我们可以得到如下等式：

$$\underbrace{\|\mathbf{y} - \bar{y}\mathbf{I}\|_2^2}_{\text{SST}} = \underbrace{\|\hat{\mathbf{y}} - \bar{y}\mathbf{I}\|_2^2}_{\text{SSR}} + \underbrace{\|\mathbf{y} - \hat{\mathbf{y}}\|_2^2}_{\text{SSE}} \quad (18)$$

相信大家一眼就会看出来，(18) 代表着直角三角形勾股定理！

如图 11 (a) 所示， $\mathbf{y} - \bar{y}\mathbf{I}$ 就是斜边对应的向量，斜边长度为 $\|\mathbf{y} - \bar{y}\mathbf{I}\|$ 。 $\hat{\mathbf{y}} - \bar{y}\mathbf{I}$ 为第一条直角边， $\mathbf{y} - \hat{\mathbf{y}}$ 代表回归模型解释的部分。 $\mathbf{y} - \hat{\mathbf{y}}$ 为第二条直角边，代表残差项，也就是回归模型不能解释的部分。

注意，图 11 中 $\mathbf{y} - \bar{y}\mathbf{I}$ 和 $\hat{\mathbf{y}} - \bar{y}\mathbf{I}$ 的起点为 $\bar{y}\mathbf{I}$ 的终点，这相当于去均值。

如图 11 (b) 所示，这个勾股定理还可以写成：

$$(\sqrt{\text{SST}})^2 = (\sqrt{\text{SSR}})^2 + (\sqrt{\text{SSE}})^2 \quad (19)$$

此外，请大家注意图中 θ ， θ 是向量 $\mathbf{y} - \bar{y}\mathbf{I}$ 和向量 $\hat{\mathbf{y}} - \bar{y}\mathbf{I}$ 的夹角，下一节会用到它。




图 11. 几何角度看三个平方和

四个直角三角形

图 11 的直角三角形是图 12 这个四面体的一个面。而图 12 这个四面体的四个面都是直角三角形！

现在请大家自己试着理解这个四面体和四个直角三角形的含义，下一章会深入分析。




图 12. 四面体的四个面都是直角三角形

10.7 拟合优度：评价拟合程度

如图 13 所示，向量 $y - \bar{y}I$ 和向量 $\hat{y} - \bar{y}I$ 之间夹角 θ 越小，说明误差越小，代表拟合效果越好。




图 13. 因变量向量和预测值向量夹角从大到小

在回归模型创建之后，很自然就要考虑这个模型是否能够很好地解释数据，即考察这条回归线对观察值的拟合程度，也就是所谓的**拟合优度** (goodness of fit)。简单地说，拟合优度是回归分析中考察样本数据点对于回归线的贴合程度。

决定系数 (coefficient of determination, R^2) 是定量化反映模型拟合优度的统计量。从几何角度， R^2 是图 12 中 θ 余弦值 $\cos\theta$ 的平方：

$$R^2 = \cos^2(\theta) \quad (20)$$

利用图 11 (b) 直角三角形三边之间的关系， R^2 可以整理为：

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (21)$$

当预测值越接近样本值， R^2 越接近 1；相反，若拟合效果越差， R^2 越接近 0。

一元线性回归

特别地，对于一元线性回归，决定系数是因变量与自变量的相关系数的平方，与模型系数 b_1 也有直接关系。

$$R^2 = \rho_{X,Y}^2 = \left(b_1 \frac{\sigma_X}{\sigma_Y} \right)^2 \quad (22)$$

其中，

$$b_1 = \rho_{X,Y} \frac{\sigma_Y}{\sigma_X} \quad (23)$$

修正决定系数

但是，仅仅使用 R^2 是不够的。对于多元线性模型，不断增加解释变量个数 D 时， R^2 将不断增大。我们可以利用修正决定系数 (adjusted R squared)，

$$\begin{aligned}
 R_{\text{adj}}^2 &= 1 - \frac{\text{MSE}}{\text{MST}} \\
 &= 1 - \frac{\text{SSE}/(n-k)}{\text{SST}/(n-1)} \\
 &= 1 - \left(\frac{n-1}{n-k} \right) \frac{\text{SSE}}{\text{SST}} \\
 &= 1 - \left(\frac{n-1}{n-k} \right) (1 - R^2) \\
 &= 1 - \left(\frac{n-1}{n-D-1} \right) \frac{\text{SSE}}{\text{SST}}
 \end{aligned} \tag{24}$$

10.8 F 检验：模型参数不全为 0

统计量

F 检验的统计量为：

$$\begin{aligned}
 F &= \frac{\text{MSR}}{\text{MSE}} = \frac{\frac{\text{SSR}}{k-1}}{\frac{\text{SSE}}{n-k}} = \frac{\text{SSR}(n-k)}{\text{SSE}(k-1)} \\
 &= \frac{\frac{\text{SSR}}{D}}{\frac{\text{SSE}}{n-D-1}} = \frac{\text{SSR} \cdot (n-D-1)}{\text{SSE} \cdot (D)} \sim F(k-1, n-k)
 \end{aligned} \tag{25}$$

原假设、备择假设

F 检验是单尾检验，原假设 H_0 、备择假设 H_1 分别为：

$$\begin{aligned}
 H_0: & b_1 = b_2 = \cdots = b_D = 0 \\
 H_1: & b_j \neq 0 \text{ for at least one } j
 \end{aligned} \tag{26}$$

如果是显著的，因变量与自变量之间存在线性关系。如果不显著，因变量与自变量之间不存在线性关系。

临界值

(25) 得到的 F 值和临界值 F_α 进行比较。临界值 F_α 可根据两个自由度 ($k-1$ 和 $n-k$) 以及置信水平 α 查表获得。 $1-\alpha$ 为置信度或置信水平，通常取 $\alpha = 0.05$ 或 $\alpha = 0.01$ 。这表明，当作出接受原假设的决定时，其正确的可能性为 95% 或 99%。

如果,

$$F > F_{1-\alpha}(k-1, n-k) \quad (27)$$

在该置信水平上拒绝零假设 H_0 , 不认为自变量系数同时具备非显著性, 即所有系数不太可能同时为零。

否则, 接受 H_0 , 自变量系数同时具有非显著性, 即所有系数很可能同时为零。

举个例子

给定条件 $\alpha = 0.01$, $F_{1-\alpha}(1, 250) = 6.7373$ 。图 6 结果告诉我们, $F = 549.7 > 6.7373$, 表明可以显著地拒绝 H_0 。

也可以用图 6 中 p 值,

$$p\text{-value} = P(F < F_{\alpha}(k-1, n-k)) \quad (28)$$

如果 p 值小于 α , 则可以拒绝零假设 H_0 。



Bk6_Ch10_02.py 计算图 6 所示方差分析表格中统计量。

10.9 t 检验: 某个回归系数是否为 0

对于一元线性回归, t 检验原假设和备择假设分别为:

$$\begin{cases} H_0: b_1 = b_{1,0} \\ H_1: b_1 \neq b_{1,0} \end{cases} \quad (29)$$

一般 $b_{1,0}$ 取 0, 也就是检验回归系数是否为 0。当然, $b_{1,0}$ 也可以取其他值。

b_1 的 t 检验统计值:

$$t_{b_1} = \frac{\hat{b}_1 - b_{1,0}}{SE(\hat{b}_1)} \quad (30)$$

\hat{b}_1 为最小二乘法 OLS 线性回归估算得到的系数, $SE(\hat{b}_1)$ 为其标准误:

$$SE(\hat{b}_1) = \sqrt{\frac{MSE}{\sum_{i=1}^n (x^{(i)} - \bar{x})^2}} = \sqrt{\frac{\frac{\sum_{i=1}^n (\varepsilon^{(i)})^2}{n-2}}{\sum_{i=1}^n (x^{(i)} - \bar{x})^2}} \quad (31)$$

上式中，MSE 为本章前文介绍的残差平均值 (mean squared error)， n 是样本数据的数量 (除 NaN)。标准误差越大，回归系数的估计值越不可靠。

如果下式成立，接受零假设 H_0 ：

$$-t_{1-\alpha/2, n-2} < T < t_{1-\alpha/2, n-2} \quad (32)$$

否则，则拒绝零假设 H_0 。

特别地，如果原假设和备择假设为：

$$\begin{cases} H_0 : b_1 = 0 \\ H_1 : b_1 \neq 0 \end{cases} \quad (33)$$

如果 (32) 成立，接受零假设 H_0 ，即回归系数不具有显著统计性；白话说，也就是 $b_1 = 0$ ，意味着自变量和因变量不存在线性关系。否则，则拒绝零假设 H_0 ，即回归系数具有显著统计性。

对于一元线性回归，对截距项系数 b_0 的假设检验程序和上述类似。 b_0 的 t 检验统计值：

$$t_{b_0} = \frac{\hat{b}_0 - b_{0,0}}{SE(\hat{b}_0)} \quad (34)$$

\hat{b}_0 为最小二乘法 OLS 线性回归估算得到的系数， $SE(\hat{b}_0)$ 为其标准误：

$$SE(\hat{b}_0) = \sqrt{\frac{\sum_{i=1}^n (\varepsilon^{(i)})^2}{n-2} \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x^{(i)} - \bar{x})^2} \right]} \quad (35)$$

t 检验统计值 T 服从自由度为 $n-2$ 的 t 分布。本节采用的 t 检验是双尾检测。比如给定显著性水平 $\alpha = 0.05$ 和自由度 $n-2 = 252-2 = 250$ ，可以查表得到 t 值，即：

$$t_{1-\alpha/2, n-2} = t_{0.975, 250} = 1.969498 \quad (36)$$

Python 中，可以用 `stats.t.ppf(1 - alpha/2, DFE)` 计算上式两值。

由于学生 t -分布对称，所以：

$$t_{\alpha/2, n-2} = t_{0.025, 250} = -1.969498 \quad (37)$$

如图 1 所示， $t_{b1} = 23.446$ ，因此：

$$t_{b1} > t_{0.975, 250} \quad (38)$$

表明参数 b_1 的 t 检验在 $\alpha = 0.05$ 水平下是显著的，也就是可以显著地拒绝 $H_0: b_1 = 0$ ，从而接受 $H_1: b_1 \neq 0$ 。回归系数的标准误差越大，回归系数的估计值越不可靠。

而 $t_{b0} = 1.759$ ，因此：

$$t_{b0} < t_{0.975, 250} \quad (39)$$

则表明参数 b_0 的 t 检验在 $\alpha = 0.05$ 水平下是不显著的，也就是不能显著地拒绝 $H_0: b_0 = 0$ 。尽管模型含有截距项，但若该项的出现是统计上不显著的（即统计上等于零），则从任何实际方面考虑，都可认为这个结果是一个过原点回归模型。

因此，系数 b_1 的 $1 - \alpha$ 置信区间为：

$$\hat{b}_1 \pm t_{1-\alpha/2, n-2} \cdot \text{SE}(\hat{b}_1) \quad (40)$$

这个置信区间的含义是，真实 b_1 在以上区间的概率为 $1 - \alpha$ 。

系数 b_0 的 $1 - \alpha$ 置信区间为：

$$\hat{b}_0 \pm t_{1-\alpha/2, n-2} \cdot \text{SE}(\hat{b}_0) \quad (41)$$

同理，真实 b_0 在以上区间的概率为 $1 - \alpha$ 。




图 14. 双尾检验

10.10 置信区间：因变量均值的区间

本书前文在介绍一元线性回归中，大家都应该见过类似图 15 的图像。图中的带宽代表预测值的置信区间。

预测值 $\hat{y}^{(i)}$ ，的 $1 - \alpha$ 置信区间：

$$\hat{y}^{(i)} \pm t_{1-\alpha/2, n-2} \cdot \sqrt{\text{MSE} \cdot \left(\frac{1}{n} + \frac{(x^{(i)} - \bar{x})^2}{\sum_{k=1}^n (x^{(k)} - \bar{x})^2} \right)} \quad (42)$$

置信区间的宽度为：

$$2 \times \left\{ t_{1-\alpha/2, n-2} \cdot \sqrt{\text{MSE}} \cdot \sqrt{\frac{1}{n} + \frac{(x^{(i)} - \bar{x})^2}{\sum_{k=1}^n (x^{(k)} - \bar{x})^2}} \right\} \quad (43)$$

随着 $|x^{(i)} - \bar{x}|$ 不断增大，置信区间宽度不断增大。当 $x^{(i)} = \bar{x}$ 时，置信区间宽度最窄。随着 MSE (mean square error) 减小，置信区间宽度减小。




图 15. 一元线性回归线置信区间

10.11 预测区间：因变量特定值的区间

预测区间 (prediction interval) 是指回归模型估计时，对于自变量给定的某个值 x_p ，求出因变量 y_p 的个别值的估计区间：

$$\hat{y}_p \pm t_{1-\alpha/2, n-2} \cdot \sqrt{\text{MSE}} \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum_{k=1}^n (x^{(k)} - \bar{x})^2}} \quad (44)$$




图 16. 一元线性回归线预测区间

10.12 对数似然函数：用在最大似然估计 MLE

似然函数是一种关于统计模型中的参数的函数，表示模型参数中的似然性。

残差的定义为：

$$\varepsilon^{(i)} = y^{(i)} - \hat{y}^{(i)} \quad (45)$$

在 OLS 线性回归中，假设残差服从正态分布 $N(0, \sigma^2)$ ，因此：

$$\Pr(\varepsilon^{(i)}) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y^{(i)} - \hat{y}^{(i)})^2}{2\sigma^2}\right) \quad (46)$$

似然函数为：

$$L = \prod_{i=1}^n \Pr(\varepsilon^{(i)}) = \prod_{i=1}^n \left\{ \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y^{(i)} - \hat{y}^{(i)})^2}{2\sigma^2}\right) \right\} \quad (47)$$

常用对数似然 $\ln(L)$ ：

$$\ln(L) = \sum_{i=1}^n \ln \Pr(\varepsilon^{(i)}) = -n \cdot \ln(\sigma\sqrt{2\pi}) - \frac{\text{SSE}}{2\sigma^2} \quad (48)$$

注意，MLE 中的 σ 为：

$$\sigma^2 = \frac{\text{SSE}}{n} \quad (49)$$

这样 $\ln(L)$ 可以写成：

$$\ln(L) = \prod_{i=1}^n P(\varepsilon^{(i)}) = -n \cdot \ln(\sigma\sqrt{2\pi}) - \frac{n}{2} \quad (50)$$

10.13 信息准则：选择模型的标准

AIC 为**赤池信息量准则** (Akaike information criterion, AIC)，定义如下：

$$\text{AIC} = \underbrace{2k}_{\text{Penalty}} - 2\ln(L) \quad (51)$$

其中， $k = D + 1$ ； L 是似然函数。

AIC 鼓励数据拟合的优良性；但是，尽量避免出现过度拟合。(51) 中 $2k$ 项为**惩罚项** (penalty)。

贝叶斯信息准则 (Bayesian Information Criterion, BIC) 也称**施瓦茨信息准则** (Schwarz information criterion, SIC)，定义如下。

$$\text{BIC} = \underbrace{k \cdot \ln(n)}_{\text{Penalty}} - 2\ln(L) \quad (52)$$

其中， n 为样本数据数量。BIC 的惩罚项比 AIC 大。

10.14 残差分析：假设残差服从均值为 0 正态分布

残差分析 (residual analysis) 通过残差所提供的信息，对回归模型进行评估，分析数据是否存在可能的干扰。

图 17 所示为残差的散点图。图 18 所示为残差分布的直方图。理想情况下，我们希望残差为均值为 0 的正态分布。为了检测残差的正态性，我们常用 Omnibus 正态检验、Jarque-Bera 检验。




图 17. 残差散点图




图 18. 残差分布直方图

Omnibus 正态检验 (Omnibus test for normality) 利用偏度 S 和峰度 K ，检验残差分布为正态分布的原假设。Omnibus 正态检验的统计值为偏度平方、超值峰度平方两者之和。Omnibus 正态检验利用 χ^2 检验 (Chi-squared test)。

代码中我们利用 `scipy.stats.normaltest()` 复现了本章前文的 Omnibus 正态检验统计量值。

残差偏度 (skewness) S 的定义为：

$$S = \text{skewness} = \frac{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^3}{\left(\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2 \right)^{\frac{3}{2}}} \quad (53)$$

残差峰度 (kurtosis) K 的定义：

$$K = \text{kurtosis} = \frac{\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^4}{\left(\frac{1}{n} \sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2 \right)^2} \quad (54)$$

K 减 3 就是超值峰度 (excess kurtosis)。

Jarque-Bera 检验也是用偏度 S 和峰度 K 来检验残差分布为正态分布的原假设：

$$JB = \frac{n}{6} \left(S^2 + \frac{1}{4} (K - 3)^2 \right) \quad (55)$$

Jarque-Bera 检验也利用 χ^2 检验。

10.15 自相关检测：Durbin-Watson

Durbin-Watson 用于检验序列的自相关。图 19 所示为残差的自相关图。




图 19. 残差自相关

Durbin-Watson 检测的统计量为：

$$DW = \frac{\sum_{i=2}^n \left((y^{(i)} - \hat{y}^{(i)}) - (y^{(i-1)} - \hat{y}^{(i-1)}) \right)^2}{\sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2} \quad (56)$$

上式本质上检测残差序列与残差的滞后一期序列之间的差异大小。 DW 值的取值区间为 $0 \sim 4$ 。当 DW 值很小时 ($DW < 1$)，表明序列可能存在正自相关。当 DW 值很大时 ($DW > 3$) 表明序列可能存在负自相关。当 DW 值在 2 附近时 ($1.5 < DW < 2.5$)，表明序列无自相关。其余的取值区间表明无法确定序列是否存在自相关。

10.16 条件数：多重共线性

在线性回归中，条件数 (condition number) 常用来检验设计矩阵 $\mathbf{X}_{k \times k}$ 是否存在多重共线性。

对 $\mathbf{X}^T \mathbf{X}$ 进行特征值分解，得到最大特征值 λ_{\max} 和最小特征值 λ_{\min} 。条件数的定义为两者的比值的平方根：

$$\text{condition number} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}} \quad (57)$$

条件数小于 30，可以不必担心多重共线性。

下一章讲到多元回归分析时，条件数的作用更明显。



Bk6_Ch10_03.py 代码复现图 1 中除 ANOVA 以外的其他统计量值。



Scikit-learn 也提供线性回归分析工具，请大家参考如下网页：

https://scikit-learn.org/stable/auto_examples/inspection/plot_linear_model_coefficient_interpretation.html